RAG médical sur MedQuAD

Répondre à des questions de santé en citant ses sources, et savoir dire « je ne sais pas »

Yasmine Belarbi · Johanna Atymmo
ISIS Castres · IA hybride, sujet 2

Yasmine et Johanna · durée ≈ 1 min

LE PROBLÈME

Un modèle seul peut inventer une réponse médicale

Modèle seul

Il répond toujours, même quand il ne sait pas, et sans dire d’où vient l’information.

RAG

Il cherche d’abord dans des documents, puis répond avec ce qu’il a trouvé et cite ses passages.

Notre objectif

Répondre seulement avec les documents, et refuser quand l’information n’y est pas.

LES DONNÉES

MedQuAD : de 16 412 réponses à 4 829 passages

16 412
réponses d'origine

15 269
après nettoyage

2 349
réponses retenues

4 829
passages de 200 mots

Textes du NIH en anglais, 9 sources différentes. On garde un échantillon équilibré entre les sources.

LE SYSTÈME

Le parcours d’une question en 5 étapes

1
Recherche
BM25 et embeddings, on garde 3 passages

2
Seuil
Score trop bas : on refuse

3
Sécurité
Règle sur les doses, alertes

4
Modèle
llama3.2:3b en local, avec citations

5
Contrôle
Citation valide, sinon refus

Trois méthodes de recherche comparées : BM25 (mots), dense (sens), hybride (les deux).

LA SÉCURITÉ

Quand le système refuse, et quand il prévient

Il refuse si

- le meilleur passage est trop éloigné de la question
- la réponse ne cite aucun passage
- une dose apparaît sans être dans les passages

Il prévient si

- la question parle de grossesse ou d’allaitement
- la question concerne un enfant
- toujours : ce n’est pas un avis médical

LE JEU DE TEST

30 questions écrites à la main, dont 5 sans réponse

30
questions de test

25
avec une réponse dans le corpus

5
sans réponse, le système doit refuser

Questions reformulées comme un patient les poserait, pour ne pas être trop faciles. Les 5 sans réponse sont vérifiées par recherche de mots-clés.

LA RECHERCHE

Le dense et l’hybride retrouvent bien mieux que BM25

Méthode	k = 1	k = 3	k = 5	k = 10
BM25	0,32	0,44	0,48	0,68
Dense	0,48	0,72	0,88	0,96
Hybride	0,60	0,72	0,80	0,96

Recall@k : part des questions où le bon document est dans les k premiers résultats.

LE SEUIL DE REFUS

Refuser plus, c’est aussi refuser à tort

Seuil	Refus justifiés (sur 5)	Refus injustifiés (sur 25)
0,45	2	0
0,55	3	3
0,57	4	3
0,60	4	6
0,65	5	13

Seuil choisi : 0,57. Aucune valeur ne sépare parfaitement les deux cas.

RÉSULTATS DU SYSTÈME

La consigne donnée au modèle change tout

Système	Refus justifiés /5	Refus injustifiés /25	Citation correcte	Fidélité
Sans recherche	2	2	sans objet	—
Extractif	4	4	13 / 21	—
Modèle, consigne 1	5	16	8 / 9	—
Modèle, consigne 2	5	6	14 / 19	0,76

Consigne 1 : très stricte, le modèle refuse 16 questions qui avaient une réponse. Consigne 2 : il ne refuse que si aucun passage n’est lié.

LA FIDÉLITÉ

Les réponses restent-elles fidèles aux passages ?

0,76

19 réponses notées à la main

10 fidèles (1) · 9 partielles (0,5) · 0 inventée (0)

Accord avec Johanna sur 6 réponses : [__ / 6]

Yasmine · ≈ 2 min · 10/14

LES ERREURS

Trois façons de se tromper

Mauvaise maladie

Question sur la fièvre Alkhurma : le système remonte Marburg, Lujo, Chapare.

Mauvais passage

Bon document, mais le passage utile n’est pas celui choisi : canal artériel, filtre de la veine cave, filariose.

Refus à tort

Question très reformulée, score sous le seuil : produits chimiques et grossesse (0,52).

Autre cas : une citation attribuée au passage voisin (radio du thorax au lieu du scanner).

LES LIMITES

Ce que nos chiffres ne disent pas

- Seulement 30 questions, dont 5 sans réponse
- Réglages faits sur les mêmes questions : résultats optimistes
- Fidélité notée par une personne, contrôlée sur 6 réponses
- Règles de sécurité basées sur des mots-clés
- Corpus presque sans médicaments : peu de doses couvertes
- Petit modèle local : moins précis qu’un grand modèle

CONCLUSION

Ce qu’on retient

La recherche

La recherche par le sens (dense, hybride) bat BM25 : 0,96 contre 0,68 à k = 10.

Le refus

Seuil, consigne et contrôles : 5 refus justifiés sur 5, 6 refus à tort sur 25.

La suite

Reranker, plus de questions, un jeu de test jamais regardé, un corpus avec des médicaments.

Merci, des questions ?

Yasmine Belarbi · Johanna Atymmo

Les deux · ≈ 5 min · 14/14