ISIS
Ingénieur
Santé numérique

Questions-réponses fiables sur des textes médicaux

Un système RAG avec citations et refus

Projet d'IA hybride, sujet 2

Binôme : Yasmine Belarbi, Johanna Atymmo

Programme : FIE5, ISIS Castres

Module : IA hybride

Date : 16 octobre 2026

Année universitaire 2026-2027

Table des matières

1 Contexte et objectif 2
2 Données et préparation du corpus 2
3 Méthode 3
4 Jeu de test 4
5 Résultats 4
6 Analyse des erreurs 6
7 Limites 7
8 Conclusion 7
Annexes 7

1 Contexte et objectif

En médecine, une réponse inventée est plus dangereuse qu'une absence de réponse. Un modèle de langage utilisé seul répond de mémoire, sans citer de source, et peut se tromper avec beaucoup d'assurance. L'objectif du projet est de construire un système qui répond aux questions d'un patient ou d'un soignant uniquement à partir de documents, qui cite les passages utilisés et qui refuse de répondre quand l'information n'est pas dans ces documents. Ce principe s'appelle le RAG (génération augmentée par récupération). Nous y avons ajouté des règles de sécurité appliquées à la réponse : pas de posologie sans passage cité qui contienne une dose, et un avertissement pour toute question sur la grossesse ou l'enfant.

Nous avons choisi l'option B du sujet, le jeu de données MedQuAD, en anglais, construit à partir de sites du NIH. Comme les réponses de trois sous-collections MedlinePlus ont été retirées pour des raisons de droits, notre fichier contient 16 412 lignes au lieu de 47 457.

Le système refuse les 5 questions de test dont la réponse n'est pas dans le corpus, alors que le même modèle sans recherche documentaire n'en refuse que 2 et répond aux 3 autres sans source. Ces résultats reposent sur 30 questions seulement, il faut donc les lire comme des ordres de grandeur (voir la section sur les limites).

2 Données et préparation du corpus

Exploration du fichier

Le fichier contient les colonnes `question`, `answer`, `source` et `focus_area`. Il y a 5 réponses vides, 14 sujets manquants et 594 réponses en double, que nous avons supprimés. Les 1 428 questions en double ne gênent pas, puisque nous n'indexons que les réponses. Une réponse fait en médiane 138 mots (201 en moyenne, 4 281 au maximum).

Deux sources représentent les deux tiers du fichier : GHR (5 430 lignes, génétique) et GARD (5 394 lignes, maladies rares). Ce sont des textes très techniques, loin de ce qu'un patient demanderait. Les autres sources sont NIDDK, NINDS, MPlusHealthTopics, NIHSeniorHealth, CancerGov, NHLBI et CDC.

Le corpus parle surtout de maladies et très peu de médicaments : seules 68 réponses contiennent une dose en mg, mcg ou ml, alors que 608 parlent de grossesse et 3 303 d'enfants (ce dernier chiffre vient surtout des textes de génétique). Beaucoup de questions de posologie n'auront donc pas de réponse dans le corpus.

Nettoyage et choix du sous-corpus

Nous avons supprimé les valeurs manquantes, les doublons et les réponses de moins de 20 mots, puis normalisé les espaces. Il reste 15 269 réponses, dont nous avons gardé 2 349 en fixant un nombre de réponses par source, pour que GHR et GARD ne dominent pas le corpus.

Source	Réponses après nettoyage	Réponses retenues
GARD	5 310	150
GHR	4 563	150
NIDDK	1 112	300
NINDS	1 043	300
MPlusHealthTopics	981	300
NIHSeniorHealth	759	300
CancerGov	693	300
NHLBI	559	300
CDC	249	249
Total	15 269	2 349

Découpage en chunks

Les réponses de 250 mots ou moins sont gardées entières. Les réponses plus longues sont coupées en morceaux de 200 mots, avec 30 mots répétés d'un morceau au suivant pour ne pas perdre le sens à la coupure. Chaque morceau (chunk) garde un identifiant comme `doc1830_c2`, sa source et son sujet. Nous obtenons 4 829 chunks de 156 mots en moyenne. Le texte d'origine contient parfois des mots collés (par exemple « adultsabout »), ce qui gêne la recherche par mots.

3 Méthode

Recherche

Nous avons comparé trois méthodes de recherche. BM25 (bibliothèque `rank_bm25`) compte les mots en commun entre la question et chaque chunk. La recherche dense transforme la question et les chunks en vecteurs avec le modèle `all-MiniLM-L6-v2` et compare ces vecteurs par similarité cosinus ; les vecteurs des chunks sont calculés une seule fois puis sauvegardés. La recherche hybride combine les deux scores, après les avoir ramenés entre 0 et 1, avec la formule $s = \alpha\, s_{dense} + (1 - \alpha)\, s_{BM25}$. Nous avons retenu $\alpha = 0{,}8$.

Génération

Le modèle de langage est `llama3.2:3b`, utilisé en local avec Ollama, à température 0. Il reçoit la question et les 3 meilleurs chunks de la recherche hybride, avec une consigne qui lui demande de répondre d'après ces passages, de les citer sous la forme [1], [2] ou [3], et de refuser sinon. Nous avons testé deux consignes. Dans la première (v1), le modèle doit refuser dès que les passages ne répondent pas à la question. Dans la seconde (v2), il doit répondre dès que les passages contiennent une information utile, même partielle, et ne refuser que si aucun passage n'a de rapport avec la question. Nous avons aussi gardé une variante extractive, qui renvoie simplement le meilleur chunk avec sa citation, sans modèle de langage.

Règles de sécurité

Le système applique plusieurs contrôles. Si le meilleur score dense est inférieur à 0,57, la question est refusée. Si la question demande une dose, au moins un des passages retenus doit contenir un nombre suivi d'une unité (mg, mcg, g ou ml), sinon la question est refusée. La réponse du modèle est aussi refusée si elle ne contient aucune citation valide, ou si elle donne une dose qui n'apparaît pas dans les passages qu'elle cite. Enfin, un avertissement est ajouté à toute question qui parle de grossesse ou d'enfant, d'après les mots de la question, y compris quand le système refuse de répondre.

4 Jeu de test

Nous avons écrit à la main 30 questions : 25 avec une réponse dans le corpus et 5 sans. Pour chaque question, nous avons noté la réponse attendue et les chunks qui la contiennent. Les sujets sont variés : symptômes, causes, traitements, examens, prévention, diagnostic, urgence, antécédents familiaux, posologie, grossesse et enfant.

Pour éviter un jeu de test trop facile, nous avons reformulé chaque question comme le ferait un patient, sans recopier les mots du texte. Par exemple, nous avons écrit « heart tracings » pour électrocardiogramme et « non-cancerous » pour bénin. Nous n'avons pas utilisé GHR ni GARD pour écrire les questions.

Les 5 questions sans réponse portent sur des sujets médicaux courants mais absents du corpus : la dose d'ibuprofène pour un enfant de 3 ans, l'ibuprofène au premier trimestre de grossesse, un verre de vin avec de l'amoxicilline, la dose de lévothyroxine et les exercices pour la fasciite plantaire. Nous avons vérifié par une recherche de mots-clés dans les 4 829 chunks qu'aucun passage n'y répond. Cinq autres questions envisagées au départ (doxycycline, migraine, metformine, goutte et syndrome des jambes sans repos) ont été remplacées parce que le corpus contenait déjà la réponse.

Après avoir lu les résultats, nous avons ajouté trois chunks aux réponses attendues (`doc1830_c3`, `doc2074_c1` et `doc1288_c0`), car leur contenu répondait bien à la question. Nous avons au contraire refusé d'autres chunks proposés par la recherche quand ils ne répondaient pas (par exemple `doc2075_c0` et `doc2041_c0`). Ces corrections ont été faites après avoir vu les résultats, ce qui rend les chiffres un peu optimistes.

5 Résultats

Qualité de la recherche

Le rappel@k est la part des 25 questions avec réponse pour lesquelles au moins un chunk attendu se trouve parmi les k premiers résultats.

Méthode	k=1	k=3	k=5	k=10
BM25	0,32	0,44	0,48	0,68
Dense	0,48	0,72	0,88	0,96
Hybride ($\alpha = 0{,}8$)	0,60	0,72	0,80	0,96

BM25 est nettement moins bon que les deux autres, ce qui est logique puisque nos questions sont reformulées alors que BM25 ne retrouve que des mots identiques. Il trouve

souvent la bonne maladie mais pas le bon passage. La recherche dense et la recherche hybride ont des résultats proches : l'hybride est meilleure au premier rang, qui est celui utilisé pour répondre, et la recherche dense est meilleure à k=5. Avec 25 questions, un écart de 0,04 correspond à une seule question, nous ne pouvons donc pas dire laquelle des deux est la meilleure.

Choix du seuil de refus

Pour les questions avec réponse, le meilleur score dense va de 0,52 à 0,84, avec une médiane de 0,64. Pour les questions sans réponse, il va de 0,40 à 0,63. Les deux groupes se chevauchent, donc aucun seuil ne sépare parfaitement les deux cas. Le tableau montre le compromis selon le seuil choisi.

Seuil	Refus justifiés (sur 5)	Refus injustifiés (sur 25)
0,45	2	0
0,53	2	1
0,55	3	3
0,57	4	3
0,60	4	6
0,65	5	13

Nous avons retenu 0,57 : il refuse 4 des 5 questions sans réponse pour 3 refus à tort, alors qu'un seuil plus haut refuse beaucoup trop de questions qui avaient une réponse. Les trois questions refusées à tort sont des reformulations fortes (produits chimiques au travail pendant la grossesse, étourdissements en se levant, attente d'une douleur thoracique). Plus la question s'éloigne des mots du texte, plus le score baisse.

Système complet

Le tableau compare le modèle sans recherche documentaire, la réponse extractive et le modèle avec les deux consignes. Un refus est justifié quand la question n'a pas de réponse dans le corpus, et injustifié quand elle en avait une. La citation est correcte quand elle renvoie à un des chunks attendus. La fidélité est expliquée plus bas.

	Sans RAG	Extractif	LLM v1	LLM v2
Refus justifiés (sur 5)	2	4	5	5
Refus injustifiés (sur 25)	2	4	16	6
Citation correcte	sans objet	13/21	8/9	14/19
Fidélité moyenne	non mesurable	non mesurée	non mesurée	0,76

La consigne v1 est trop prudente : elle refuse 16 questions sur 25 qui avaient une réponse. Sur 11 refus du modèle, 7 viennent du modèle lui-même (le bon chunk faisait pourtant partie des 3 passages) et 4 de la recherche. La consigne v2 ramène les refus injustifiés à 6 sur 25 sans perdre aucun des 5 refus justifiés. Ces 6 refus viennent du seuil (3 cas), de la règle sur les doses (1 cas, car la recherche n'avait pas trouvé le bon chunk), d'une absence de citation (1 cas) et d'un refus du modèle (1 cas). Nous avons choisi la consigne v2 après avoir vu les résultats sur ces mêmes questions, son gain est donc un peu optimiste.

Comparaison avec le modèle sans recherche documentaire

Posées au même modèle sans aucun passage, trois des cinq questions hors corpus reçoivent une réponse sans source : l'ibuprofène serait déconseillé pendant la grossesse, le vin serait généralement sans danger avec l'amoxicilline tout en étant à éviter, et quatre exercices détaillés sont proposés pour la fasciite plantaire. Ces réponses sont plausibles mais on ne peut pas les vérifier, ce qui est le risque que le RAG cherche à éviter. Le modèle ne refuse que les deux questions de dose. Nous avons relu ces réponses à la main, car la détection automatique d'un refus par mots-clés est approximative.

Avertissements grossesse et enfant

Ils se déclenchent sur toutes les questions concernées, qu'elles soient répondues ou refusées, par exemple pour la dose d'ibuprofène chez l'enfant ou la toxoplasmose pendant la grossesse.

Fidélité

Nous avons noté à la main les 19 réponses données par le modèle avec la consigne v2. Une réponse reçoit 1 si toutes ses affirmations sont soutenues par les passages cités, 0,5 si au moins une affirmation n'est pas soutenue, est déformée ou mal attribuée, ou si la réponse est incomplète, et 0 si elle n'est pas soutenue ou si elle est hors sujet. Quand un mot semblait absent d'un passage, nous l'avons recherché dans le texte complet, car l'affichage était coupé. Cette vérification a corrigé trois de nos premières notes (le filtre de la veine cave, la dose pour la fièvre Q et l'échocardiogramme).

La fidélité moyenne est de 0,76 (14,5 sur 19) : 10 réponses ont la note 1, 9 ont la note 0,5 et aucune n'a la note 0. Le système ne s'éloigne donc jamais complètement des passages, mais il n'en reprend parfois qu'une partie. [À COMPLÉTER : nombre de réponses notées aussi par Johanna et nombre d'accords.]

6 Analyse des erreurs

Certaines erreurs viennent d'une mauvaise maladie. Pour la fièvre hémorragique d'Alkhurma, BM25 et la recherche hybride remontent d'autres fièvres hémorragiques (Marburg, Lujo, Chapare) parce que les textes partagent beaucoup de mots. Pour la crise cardiaque, la recherche trouve une autre maladie du cœur.

D'autres erreurs viennent d'un bon document mais d'un mauvais passage. C'est le cas du canal artériel, du filtre de la veine cave et de la filariose : la recherche trouve le bon sujet mais pas le chunk qui répond, par exemple la définition ou la prévention au lieu du traitement. Le système répond alors à côté ou refuse.

Le seuil refuse à tort trois questions qui avaient une réponse, parce que le patient parle d'« inconfort thoracique » alors que le texte dit « crise cardiaque ».

La question sur la fasciite plantaire obtient un score de 0,63 car le sujet ressemble à d'autres douleurs, et elle passe donc le seuil. Aucune règle de sécurité ne l'arrête, mais le modèle avec la consigne v2 la refuse, ce qui compense la limite du seuil.

Le modèle attribue parfois une phrase au mauvais passage ou en tire une conclusion fausse.

Par exemple, il écrit que la radio du thorax permet de détecter la plupart des embolies pulmonaires, alors que le passage parle du scanner. Une réponse assurée sur un mauvais passage est plus risquée qu'un refus.

Enfin, pour la diverticulose et la rétinopathie diabétique, le modèle recopie un passage proche sans donner l'information qui répond à la question (les aliments à éviter, l'examen annuel des yeux).

7 Limites

Avec 30 questions, une question pèse 4 points de pourcentage, et 20 points parmi les 5 questions sans réponse. La valeur d'α, le seuil, la consigne v2 et l'ajout de trois chunks attendus ont été décidés après avoir vu les résultats sur ces mêmes questions, donc les chiffres sont un peu optimistes. La fidélité a été notée à la main, avec un accord partiel entre les deux notatrices [À COMPLÉTER].

La règle sur les doses vérifie seulement qu'une dose existe dans le passage, pas que c'est la dose du bon médicament, et elle peut se déclencher sur des taux sanguins exprimés en mg/dL. Le corpus parle surtout de maladies et contient très peu de médicaments, et son texte contient des mots collés. Enfin, un modèle de 3 milliards de paramètres est trop prudent avec la consigne v1, parfois confus avec la v2, et lent sur un ordinateur sans carte graphique.

8 Conclusion

Un RAG avec une recherche hybride, un seuil de refus, des règles de sécurité et une consigne adaptée refuse les questions hors corpus et cite ses sources, ce que le même modèle sans recherche ne fait pas. En contrepartie, il refuse à tort 6 questions sur 25, surtout à cause des limites de la recherche et du seuil quand le patient reformule loin du texte.

Plusieurs améliorations sont possibles : reclasser les 10 meilleurs chunks avec un cross-encoder pour réduire les erreurs de passage, comparer deux modèles d'embeddings (par exemple `all-MiniLM-L6-v2` et `multi-qa-MiniLM-L6-cos-v1`), agrandir le jeu de test avec des questions écrites par quelqu'un qui n'a pas vu le corpus, citer plusieurs passages, et utiliser de vraies notices de médicaments pour tester sérieusement la posologie.

Annexes

Annexe A : notes de fidélité

Notes des 19 réponses du modèle (consigne v2), dans l'ordre : 0,5 ; 0,5 ; 0,5 ; 1 ; 1 ; 0,5 ; 0,5 ; 1 ; 1 ; 0,5 ; 1 ; 0,5 ; 1 ; 1 ; 0,5 ; 1 ; 0,5 ; 1 ; 1.

Annexe B : consigne v2 donnée au modèle

> You are a medical information assistant. Use the passages below to answer the question. If the passages contain information that answers the question, even partly, answer using only that information and cite the passages as [1], [2] or [3]. Do not add anything that is not in the passages. Never give a dose unless it appears in a passage. Only if none of the passages is related to the question, reply exactly : I

don't know based on the available documents.

Annexe C : sources

— MedQuAD, questions-réponses issues de sites du NIH, jeu de données Kaggle : `https://www.kaggle.com/datasets/pythonafroz/medquad-medical-question-answer-for-`

— Notebook de cours `S2_demo_RAG_corrige.ipynb` (ISIS Castres, IA hybride), point de départ du projet.

— Ollama et le modèle `llama3.2:3b` : `https://ollama.com`